ChatGPT 對話過程紀錄 (AI-Assisted Inquiry Log)

作業主題：多元線性回歸 (Multiple Linear Regression) 與 CRISP-DM 實作分析

學生學號： 7115064153　**資料集選擇：** Kaggle: Predict the Flood (Playground Series s4e5)

對話公開連結： https://chatgpt.com/share/6ad5d4cd-6388-83e8-bcbd-3923960e8502

紀錄時間： 2026-10-19

🙋 **提問 1 (資料集選題諮詢)：**

「請推薦適合多元線性回歸 (Multiple Linear Regression) 的 Kaggle 公開資料集，特徵數需介於 10 到 20 個之間，包含連續數值預測目標，並請建議以 CRISP-DM 架構進行分析的最佳資料集。」

🤖 **ChatGPT 回覆 1：**

依據你的條件——**特徵數介於 10–20 個、具有連續數值預測目標，並適合使用 CRISP-DM 架構進行分析**——我為你評估最適合的三大資料集：

- **1. Kaggle: Predict the Flood (Flood Prediction Dataset - S4E5) [強烈首選]**：擁有 20 個純連續數值特徵，預測目標 `FloodProbability`。無任何類別型變數編碼困擾，無缺失值，特徵相關性結構極佳，非常適合多元線性回歸基準線、5大特徵選取與五大回歸假設檢定。
- **2. House Sales in King County, USA**：約 19 個特徵，預測房價 `price`。能探討面積、屋齡與共線性，但需處理極端值與偏態分配。
- **3. Avocado Prices**：約 12 個特徵，預測酪梨價格 `AveragePrice`。適合分析特徵高度相關與時間序列衍生特徵。

建議結論：針對課堂作業要求之 10~20 個特徵與特徵選取比對，選擇 **Predict the Flood** 最為標準、高效且易於解釋。

🙋‍♂️ 提問 2 (特徵選擇與前處理規劃)：

「如果我決定選擇 Kaggle 的『Predict the Flood (Flood Prediction Dataset)』資料集（20 個特徵），請幫我規劃如何進行特徵選擇（例如比較 SelectKBest、RFE、Sequential Feature Selection、Lasso L1），並說明如何切分訓練與測試集？」

🤖 ChatGPT 回覆 2：

這是一份非常規範的特徵選擇規劃流程，請遵循以下步驟落實：

一、資料切分與防洩漏原則 (Data Leakage Prevention)

1. **切分比例**：採用 80% 訓練集 (Train) 與 20% 測試集 (Test)，固定 `random_state=42` 保證可重現性。
2. **特徵縮放**：必須使用 `StandardScaler` 在訓練集上 `fit_transform`，測試集僅執行 `transform`，避免資料洩漏。

二、5 大特徵選擇演算法對比設計 (目標選取 14 個最佳特徵)

- **1. SelectKBest (f_regression)**：計算單變量 F-檢定統計量，選取線性關聯度前 14 名特徵。
- **2. RFE (Recursive Feature Elimination)**：以多元線性回歸為基底模型，逐步遞迴剔除權重最小的特徵直至 14 個。
- **3. Sequential Feature Selection (Forward SFS)**：以交叉驗證（CV=3）為基準，貪婪前向依序加入提升模型效能最佳的特徵。
- **4. Lasso (L1 Regularization)**：加入 L1 懲罰項使不重要特徵係數歸零，依絕對值排序選取前 14 名。
- **5. Permutation Importance**：隨機打亂單一特徵數值，衡量模型測試誤差之惡化程度。

共識投票法 (Consensus Voting)：統計每項特徵在 5 大演算法中獲得的票數，票數最高之 14 個特徵即為最終精簡模型特徵子集。

🙋 **提問 3 (五大回歸假設檢定與預測區間)：**

「在多元線性回歸的評估階段 (CRISP-DM Evaluation)，如何檢驗線性回歸的五大假設（常態性、同質變異、獨立性、線性、無多重共線性）？在繪製預測圖時，如何計算並加上 95% 信賴區間或預測區間？」

🤖 **ChatGPT 回覆 3：**

一、多元線性回歸五大基本假設檢定

假設名稱	檢定方法與診斷工具	理想判準標準
1. 線性關係 (Linearity)	殘差 vs 擬合值散佈圖 (Residuals vs Fitted)	殘差隨機對稱散佈於 0 刻度水平線兩側，無明顯 U 型或非線性彎曲趨勢。
2. 殘差常態性 (Normality)	Q-Q 圖 (Quantile-Quantile Plot) 與 Jarque-Bera 檢定	點位緊密貼合 45 度參考紅線，殘差直方圖呈現鐘形常態對稱。
3. 殘差同質變異 (Homoscedasticity)	Scale-Location 圖與 Breusch-Pagan 檢定	殘差離散程度不隨預測值增大而呈現擴大（漏斗狀），方差恆定。
4. 殘差獨立性 (Independence)	Durbin-Watson (DW) 統計檢定	DW 統計量介於 1.5 至 2.5 之間，接近 2.0 代表無一階自我相關。
5. 無嚴重多重共線性 (No Multicollinearity)	變異數膨脹因子 (Variance Inflation Factor, VIF)	各特徵之 VIF < 5（嚴格標準）或 < 10，代表特徵間相互獨立。

二、95% 信賴區間 (CI) vs 預測區間 (PI) 繪製機制

- **信賴區間 (Confidence Interval, CI)**：反映母體平均預測值 $\hat{y}$ 的估計不確定性，公式為 $\hat{y} \pm t_{\alpha/2, n-p-1} \cdot s_{\hat{y}}$，區間較窄。
- **預測區間 (Prediction Interval, PI)**：反映個別新樣本觀測值 y_0 的預測範圍，包含個別隨機誤差 ϵ，公式為 $\hat{y} \pm t_{\alpha/2, n-p-1} \cdot \sqrt{MSE + s_{\hat{y}}^2}$，區間較寬。
- **可視化呈現**：在排序後的預測曲線上，以深色半透明陰影填入 95% CI，淺色半透明陰影填入 95% PI，並將真實測試點繪製於圖上，直觀展現區間包覆率。

🙋 **提問 4 (網路主流與更優解法對比)：**

「針對這個洪水預測資料集，除了多元線性回歸之外，網路上在 **Kaggle** 競賽中主流使用的優秀解法（例如 **LightGBM**、**XGBoost**、**CatBoost** 或神經網路）有哪些特點？與線性回歸相比的優缺點是什麼？」

🤖 **ChatGPT 回覆 4：**

一、Kaggle 頂尖解法關鍵發現：特徵工程 + GBDT 樹模型

1. **特徵工程奧秘（The Power of Feature Aggregation）**：在 Kaggle S4E5 中，頂尖參賽者發現該資料集為合成資料，所有 20 個特徵具有對稱且近似的權重。只要創造一個新特徵 `f_sum = X.sum(axis=1)`（20項特徵總和）與 `f_std`，模型效能（R^2）便能由 0.845 劇烈躍升至 0.869 以上！
2. **主流演算法陣列：**
   - **LightGBM / XGBoost / CatBoost**：梯度提升決策樹具備自動捕獲特徵高階非線性交互作用、抗異常值能力，並支援早停法（Early Stopping）。
   - **Multi-Layer Perceptron (MLP)**：深層神經網路透過多層非線性激活函數學習潛在特徵表示。
   - **Stacking / Blending 模型融合**：以 Ridge 回歸作為 Meta-Learner，結合多個樹模型與神經網路的預測機率。

二、多元線性回歸 vs GBDT 主流解法深度對比

維度指標	多元線性回歸 (本作業基準)	GBDT 主流模型 (LightGBM/CatBoost)
預測能力 (R^2)	約 0.8445（無特徵工程時表現已極佳）	約 0.8690+（搭配特徵工程與調參）
計算成本與訓練時間	極低（毫秒級閉式解或快速收斂）	較高（需數分鐘，依賴 GPU/多核心）
模型可解釋性 (Interpretability)	極高（每個係數 eta_j 代表特徵對洪水機率的邊際增益）	黑盒子（需仰賴 SHAP、Tree SHAP 等後驗工具解釋）
五大假設約束	嚴格（依賴常態性、同質變異、無共線性等統計假設）	完全無分布假設（Non-parametric 非參數模型）

總結：多元線性回歸在該資料集上已具備極高的基準預測力（$R^2 > 0.84$），且具備物理可解釋性與嚴謹統計推論基礎；而 GBDT 則是在追求極限競賽指標時的必備利器。