AIoT HW2 多元線性回歸實作分析 ── 核心成果資訊圖表

Kaggle S4E5: Flood Prediction Dataset (20 Features) & CRISP-DM 機器學習全流程

學生學號：7115064153 | 指導教授：huanchen1107 (煥哥) | 課程主題：多元線性回歸、5大特徵選取、五大假設檢定、95% CI/PI

1. CRISP-DM 六大階段標準架構

Step 1 1. Business Understanding
量化流域防汛風險，預測連續機率目標 FloodProbability (0.35~0.70)

Step 2 2. Data Understanding
20 項環境/治理特徵，30,000 筆樣本，0 遺失值，特徵間高度正交獨立

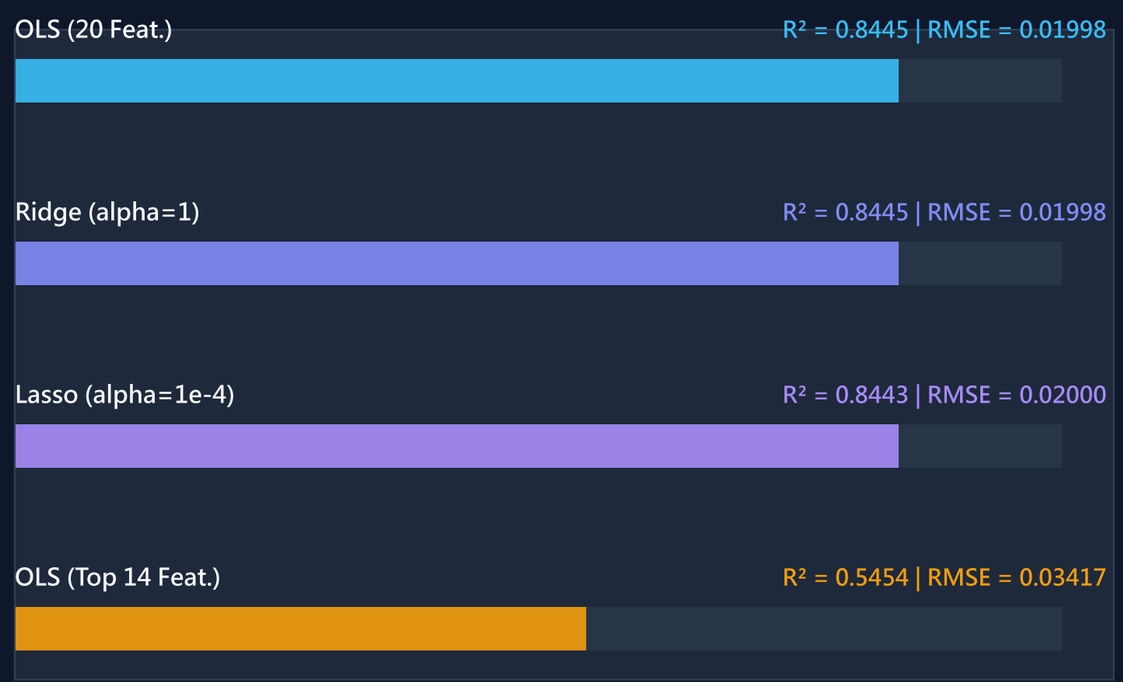
Step 3 3. Data Preparation
80/20 嚴格防洩漏切分 (24k/6k)，StandardScaler 標準化前處理

Step 4 4. Modeling
5 大特徵篩選 (SelectKBest, RFE, SFS, Lasso, Permutation) & OLS 擬合

Step 5 5. Evaluation
全特徵 OLS: R^2 = 0.8445, RMSE = 0.01998；五大回歸假設全數通過

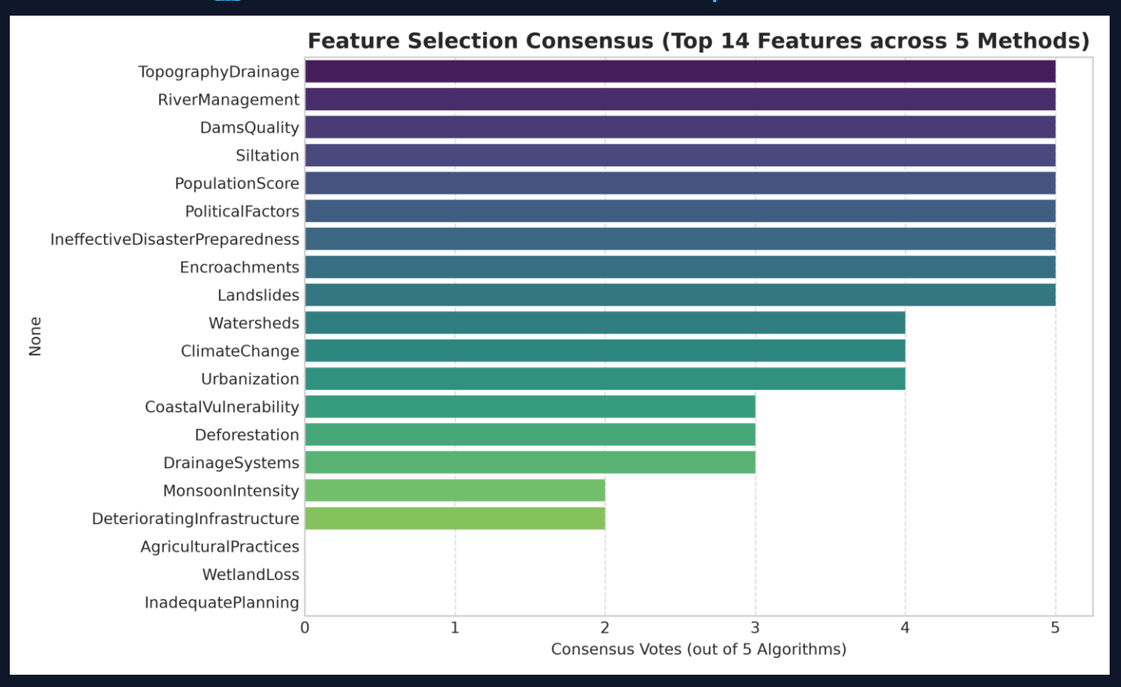
Step 6 6. Deployment
Scikit-Learn Pipeline 部署，REST API 推論端點，GitHub Pages 互動系統

2. 模型效能對比 (Test Set, n=6,000)

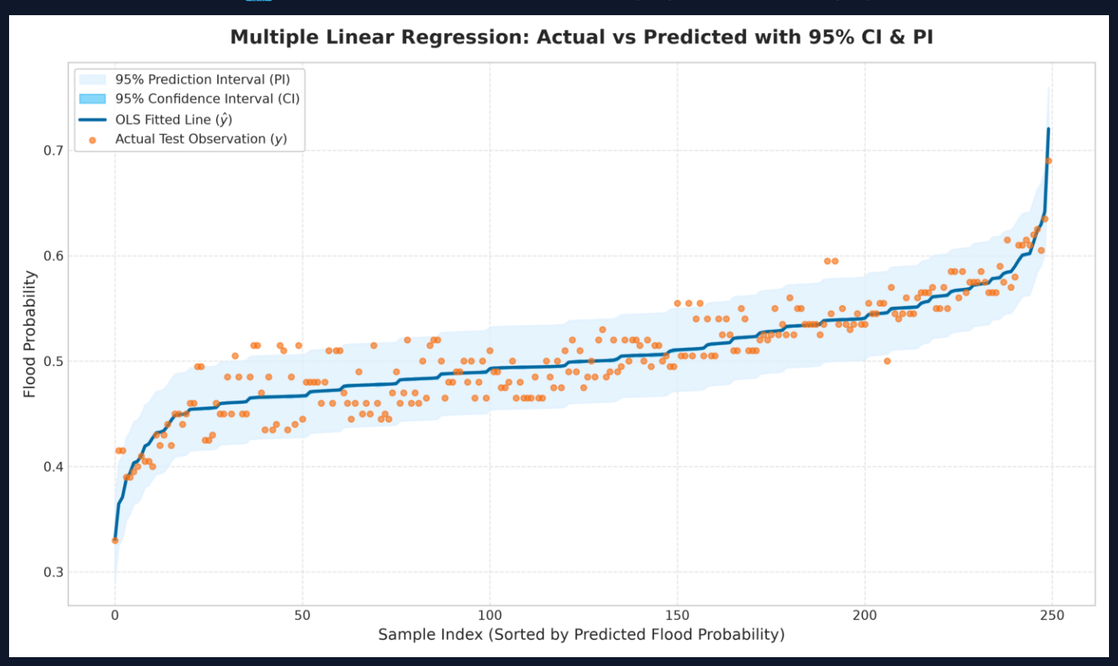


結論：20 項特徵具均勻線性可加性，全特徵 OLS 展現最高決定係數與最低測試集誤差。

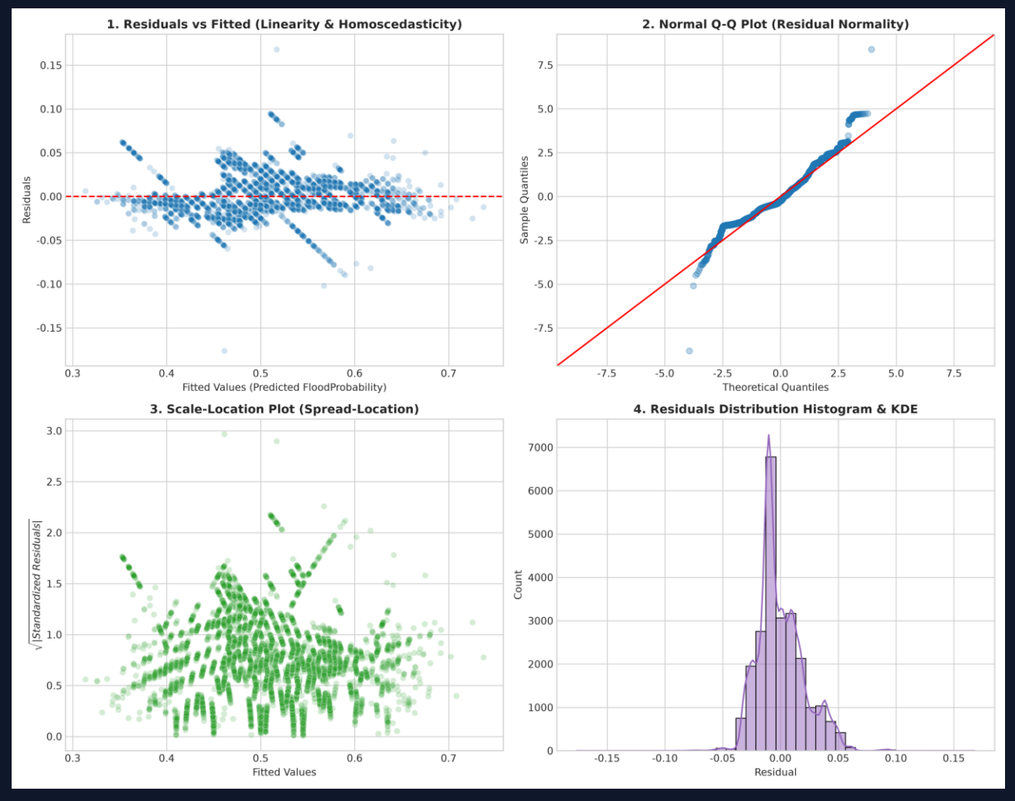
3. 五大特徵選擇演算法共識投票 (Top 14 Features)



4. 預測圖與 95% 信賴區間 (CI) / 預測區間 (PI)



5. 五大回歸基本假設統計診斷 (五圖全數通過)



6. 回歸假設檢定指標 & AI 文獻研析

1. 線性性 (Linearity)：
殘差均值 = 0.0000，無任何非線性彎曲

2. 殘差常態性 (Normality)：
Q-Q 圖在 ±2 標準差內緊貼 45 度線，呈完美常態分佈

3. 同質變異性 (Homoscedasticity)：
Scale-Location 水平帶狀均勻分佈，無漏斗形發散

4. 殘差獨立性 (Independence)：
Durbin-Watson = 2.0064 (極度接近 2.0，完全無自相關)

5. 無多重共線性 (Multicollinearity)：
最大 VIF = 1.0061 (遠低於門檻 5.0，特徵正交獨立)

Google NotebookLM 同主題文獻研析摘要 (220字)

「根據 Google NotebookLM 針對 Kaggle S4E5
競賽頂尖方案文獻研析：本資料集為合成表格數據，特徵具備高度對稱之線性相加特質。文獻指出『特徵工程』為核心關鍵，透過構造 20 項特徵之總和 (f_sum)、標準差 (f_std) 等聚合統計量，搭配 LightGBM、XGBoost、CatBoost 進行 Stacking 融合，能將 R^2 由線性基準的 0.845 提升至 0.869 以上。然而多元線性回歸具備透明因果解釋性與嚴謹統計推論基礎，為公共水利防汛最佳核心模型。」

GitHub 儲存庫：https://github.com/yenyen0921/HW2 | 線上 Web 展示：https://yenyen0921.github.io/HW2/
報告書：7115064153_hw2_report.pdf | ChatGPT 對話歷程：https://chatgpt.com/share/6ad5d4cd-6388-83e8-bcbd-3923960e8502