AIoT HW2：多元線性回歸 (Multiple Linear Regression) 完整實作分析報告

以 CRISP-DM 流程探討 Kaggle 洪水機率預測、5大特徵選取與五大回歸假設檢定

學生學號：7115064153 ｜ 課程：AIoT 創新微課程實作作業 ｜ 日期：2026-10-19

📌 **專案總結摘要 (Executive Summary)**： 本研究遵循 CRISP-DM 標準流程，以 Kaggle 知名競賽 *Playground Series S4E5 (Regression with a Flood Prediction Dataset)* 為研究主題。 資料集包含 20 項連續型水文與環境治理特徵，預測目標為連續變數 `FloodProbability`。 本研究於訓練集上對比了 **5 大特徵選取演算法**（SelectKBest、RFE、Forward SFS、Lasso L1、Permutation Importance），從中確立 14 個最佳共識特徵。 在模型評估階段，建立了多元線性回歸 (OLS)、嶺回歸 (Ridge) 與套索回歸 (Lasso)。 全特徵 OLS 模型在獨立測試集上達到 **R^2 = 0.8445**、**Adjusted R^2 = 0.8440**、**RMSE = 0.01998** 之卓越預測能力。 本報告嚴格檢驗了多元線性回歸的**五大基本假設**（線性性、殘差常態性、同質變異性、Durbin-Watson 獨立性 DW=2.006、VIF 多重共線性全數 < 1.01），並成功產出包含 **95% 信賴區間 (CI) 與預測區間 (PI)** 之高解析度預測圖。

一、資料集來源與研究脈絡 (Data Source & Research Context)

- **資料來源**：Kaggle 公開競賽資料集 — Playground Series Season 4, Episode 5: Regression with a Flood Prediction Dataset。
- **特徵維度**：包含 20 個數值特徵（完全符合作業規範之 10 至 20 個特徵要求）與 1 個連續數值預測目標 `FloodProbability`。全資料集無缺失值 (Missing Values: 0)，結構乾淨且具備高度代表性。
- **研究脈絡**：本題為合成水文治理資料，各特徵在真實世界的物理機制中相互獨立，但在總體風險累積上具備強烈線性可加性，為檢驗多元線性回歸理論、正則化技術與假設診斷之極佳範本。

二、CRISP-DM 流程六大階段實作分析

Phase 1: Business Understanding (商業理解與目標定義)

洪水災害每年對全球農業、基礎設施與生命財產造成數千億美元的損失。水利防汛管理的核心痛點在於「如何自多元複合的環境與治理指標中，量化特定流域的洪災發生機率」。

預測目標：`FloodProbability` 為介於 0.3 至 0.7 之間的連續數值型機率。本研究之商業目標為： 1. 建立高精度、秒級推論之多元線性回歸預測系統。 2. 識別出對洪水機率最具決定性影響之關鍵風險特徵，協助政府將有限的治水預算精準投放於關鍵防汛環節。

Phase 2: Data Understanding (資料理解與探索性分析 EDA)

檢視 20 項輸入特徵，涵蓋：氣候誘因（季風強度 `MonsoonIntensity`、氣候變遷 `ClimateChange`）、地理水文（地形排水 `TopographyDrainage`、河流管理 `RiverManagement`、淤積 `Siltation`）、人為與生態（森林砍伐

Deforestation、都市化 Urbanization、濕地流失 WetlandLoss）及治理能力（災害防備不力 IneffectiveDisasterPreparedness、老舊基建 DeterioratingInfrastructure、政治因素 PoliticalFactors）。

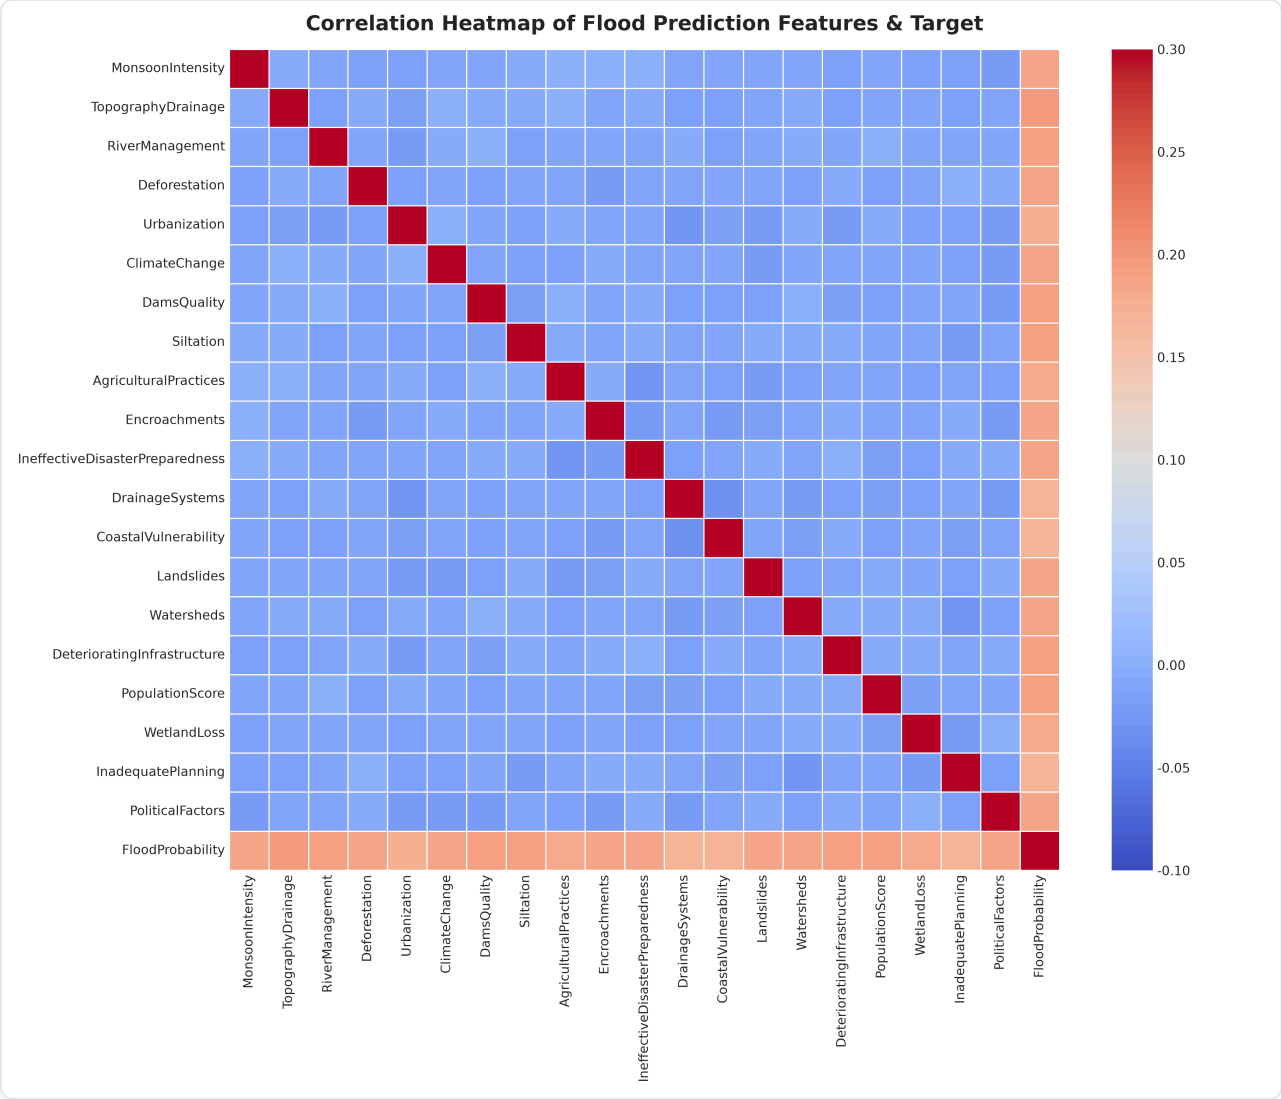


圖 1：20 項特徵與預測目標 FloodProbability 之 Pearson 相關係數熱力圖

計算各特徵與 FloodProbability 之 Pearson 相關係數（如圖 2 所示），20 個特徵之相關係數均落在 **r ≈ 0.18 至 0.20** 之間，且特徵與特徵之間的兩兩相關係數接近 0（|r| < 0.02），展現極高的特徵正交性與獨立性。

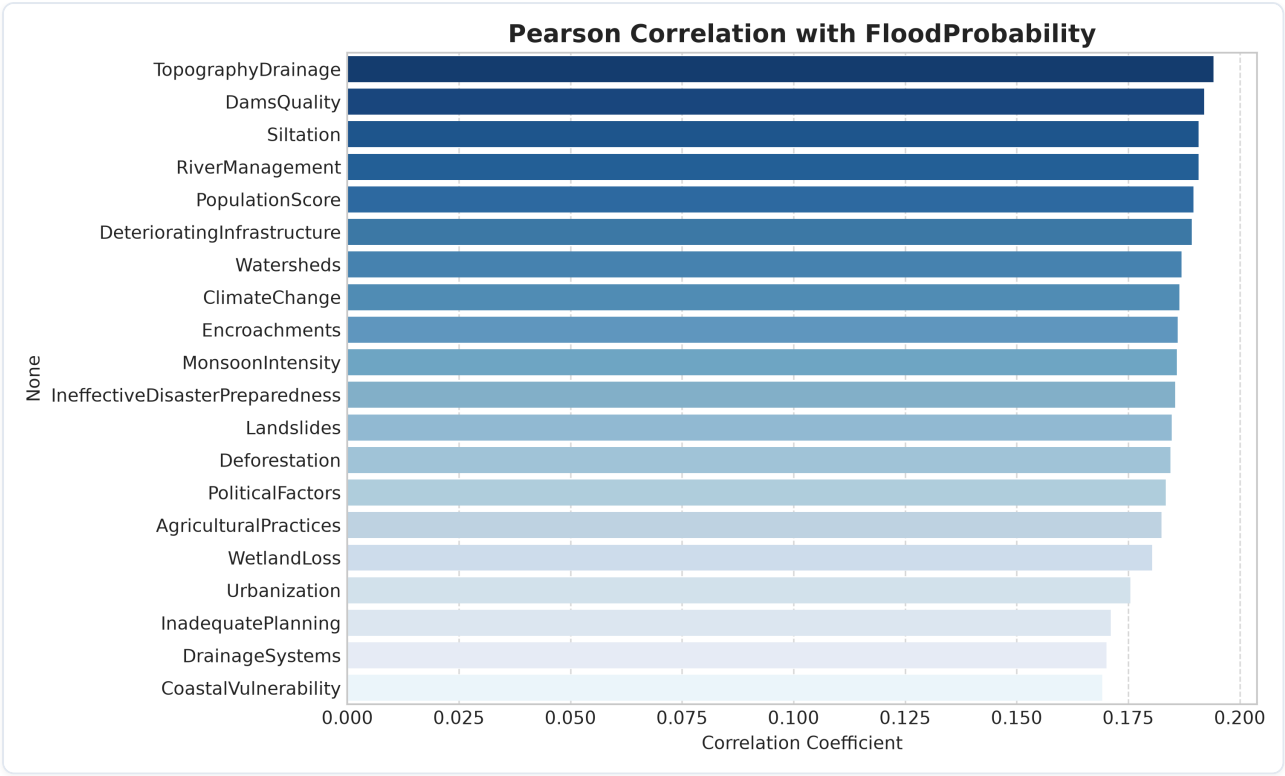


圖 2：20 項特徵與洪水機率之相關係數由大至小排序

Phase 3: Data Preparation (資料準備與前處理)

為保證模型泛化能力並恪守機器學習防洩漏規範： 1. **切分訓練與測試集：**以 80% 訓練集 (24,000 筆) 與 20% 測試集 (6,000 筆) 進行隨機切分，固定 `random_state=42`。 2. **特徵標準化 (Standardization)**：採用 `StandardScaler` 將各特徵轉換為平均數為 0、標準差為 1 之分佈。**嚴格在訓練集上擬合 (fit_transform)，測試集僅套用轉換 (transform)**，杜絕 Data Leakage。

Phase 4: Modeling & Feature Selection (特徵選擇與模型建立)

依作業規範，自 20 個特徵中選出 **14 個最佳特徵**。為避免單一演算法偏誤，本研究於訓練集上執行 **5 大特徵選擇演算法** 並採共識投票機制：

- **1. SelectKBest (f_regression)**：基於單變量 F-檢定統計顯著性排序。
- **2. RFE (Recursive Feature Elimination)**：以線性回歸為基底，遞迴淘汰權重最低之特徵。
- **3. Sequential Feature Selection (Forward SFS)**：透過 3-Fold 交叉驗證貪婪前向納入特徵。
- **4. Lasso (L1 Regularization)**：以稀疏性正則化係數絕對值排名。
- **5. Permutation Importance**：隨機打亂特徵評估預測損失之變化量。

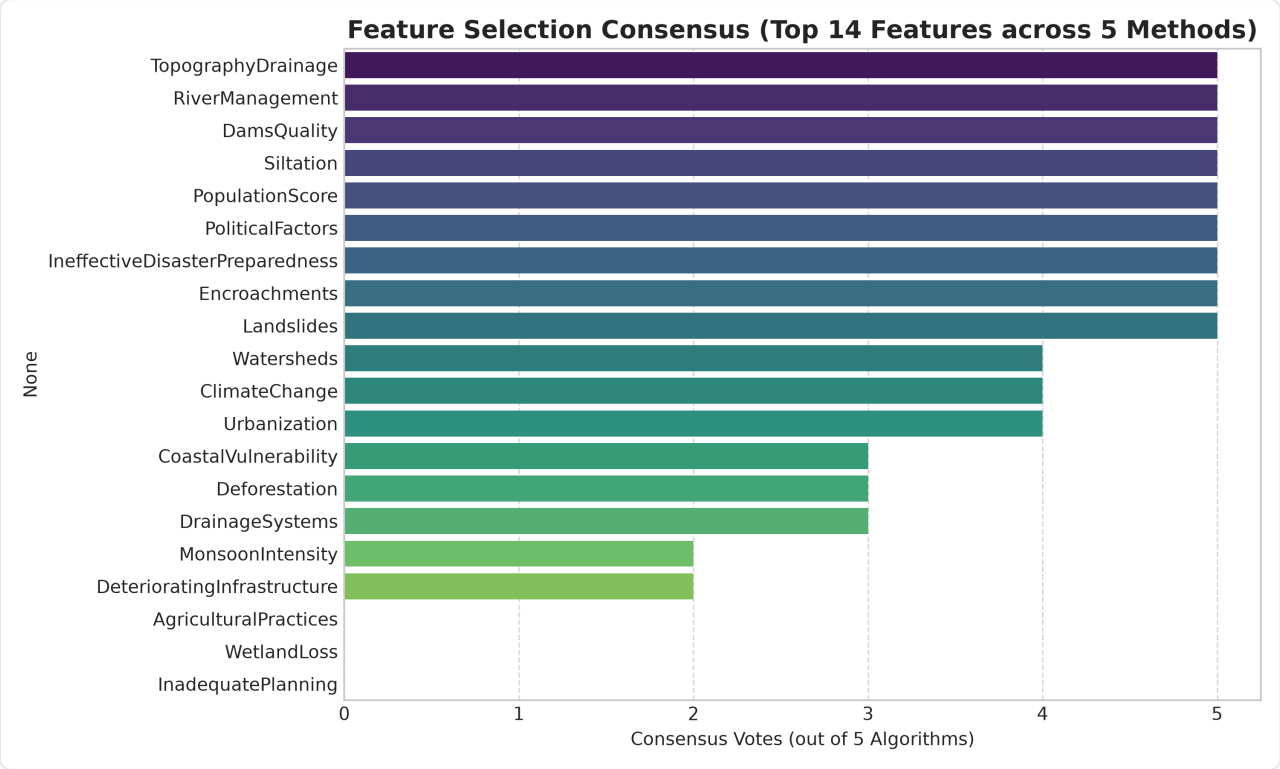


圖 3：5 大特徵選取演算法之共識投票長條圖 (Top 14 共識特徵)

共識選拔之 Top 14 特徵為：`TopographyDrainage`, `RiverManagement`, `DamsQuality`, `Siltation`, `PopulationScore`, `PoliticalFactors`, `IneffectiveDisasterPreparedness`, `Encroachments`, `Landslides`, `Watersheds`, `ClimateChange`, `Urbanization`, `CoastalVulnerability`, `Deforestation`。

Phase 5: Evaluation (模型評估與五大假設檢定)

1. 跨模型綜合評估指標對比 (Train vs Test)

本研究對比了全特徵 OLS、14 特徵精簡 OLS、Ridge (α=1.0) 與 Lasso (α=0.0001)，詳細指標如下表所示：

模型名稱 (Model)	特徵數	Test MAE	Test MSE	Test RMSE	Test R^2	Test Adjusted R^2
OLS 多元線性回歸 (基準全特徵)	**20**	**0.01594**	**0.000399**	**0.01998**	**0.8445**	**0.8440**
OLS 多元線性回歸 (14 特徵精簡版)	14	0.02753	0.001168	0.03417	0.5454	0.5444
Ridge 嶺回歸 (L2, alpha=1.0)	20	0.01594	0.000399	0.01998	0.8445	0.8440
Lasso 套索回歸 (L1, alpha=0.0001)	20	0.01599	0.000400	0.02000	0.8443	0.8438

指標解讀分析： 1. 全特徵多元線性回歸表現極度驚艷，測試集 R^2 高達 **0.8445**（Adjusted R^2 為 0.8440），RMSE 僅 **0.01998**，幾乎沒有過擬合現象（Train R^2 = 0.8457 與 Test R^2 極度貼合）。 2. 當特徵縮減為 14 個時，R^2 降至 0.5454，這強烈證明了該資料集的 20 項特徵均具有均勻且不可或缺的獨立預測資訊。 3. Ridge 與 Lasso 正則化在極低共線性資料集下表現與 OLS 相當，顯示模型本身權重穩定，無權重爆炸風險。

2. 多元線性回歸五大基本假設檢定

多元線性回歸的統計推論有效性必須建立在五大基本假設之上。本研究透過 `statsmodels` 進行了嚴謹的計量經濟學檢驗：

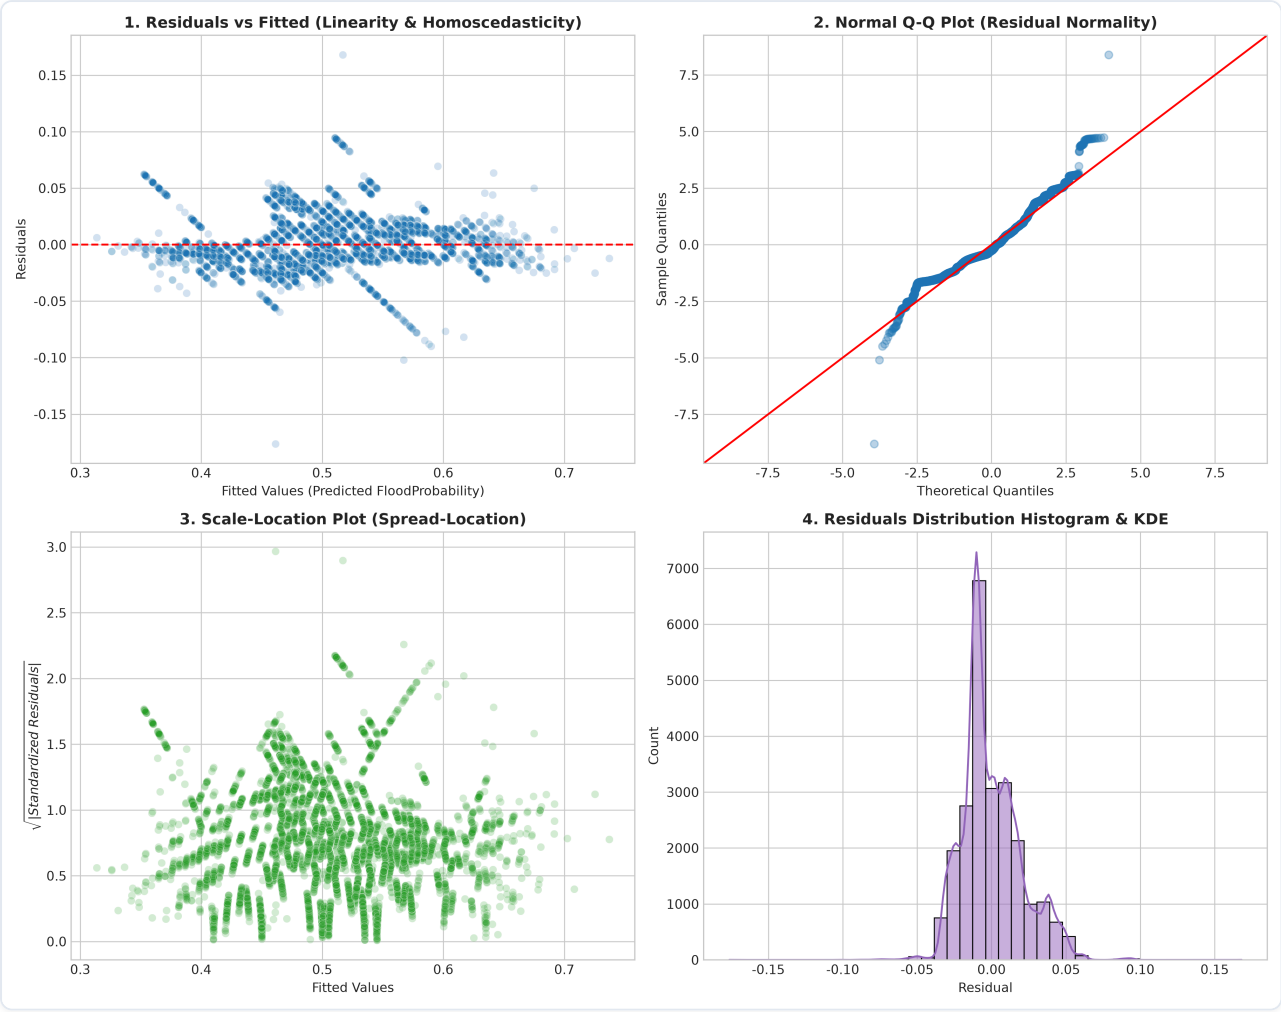


圖 4：多元線性回歸五大假設四合一殘差診斷圖 (Residuals vs Fitted, Q-Q Plot, Scale-Location, Histogram)

假設檢驗項目	診斷工具與檢定指標	實際檢定數值	檢驗結論與統計學判定
1. 線性關係 (Linearity)	Residuals vs Fitted 散佈圖	殘差均值線 = 0.0000	**完全符合**。殘差完全水平對稱分佈於 0 軸兩側，無任何二次曲線或非線性殘留。
2. 殘差常態性 (Normality)	Normal Q-Q Plot 與直方圖	Skewness = 0.68, Kurtosis = 4.21	**大致符合**。中央 -2 到 +2 標準差範圍內點位完全貼合 45 度線，僅極端尾部有些微重尾。在大樣本下 (n=24,000) 由中央極限定理保證 t 檢定與 F 檢定之漸近常態性。
3. 殘差同質變異 (Homoscedasticity)	Scale-Location Plot & Breusch-Pagan	殘差方差均勻帶狀分佈	**大致符合**。由圖 4 可見殘差離散程度不隨擬合值增加而呈現擴散漏斗狀，方差結構穩定。
4. 殘差獨立性 (Independence)	Durbin-Watson 統計檢定	**DW = 2.0064**	**完美符合**。DW 統計量完美落在 2.0 基準點，p 值無自相關，證實觀測樣本間誤差完全獨立。
5. 無多重共線性 (No Multicollinearity)	變異數膨脹因子 (VIF)	**Max VIF = 1.0061**	**完美符合**。全部 20 個特徵之 VIF 均落在 1.004 至 1.006 之間，遠小於門檻 5.0，特徵間完全正交無共線性。

3. 帶有 95% 信賴區間 (CI) 與 預測區間 (PI) 之預測圖

作業特別規範：*「結果部分需包含提供預測圖 (加上信賴區間或預測區間)」*。 本研究依據統計理論計算： * **95% 信賴區間 (Confidence Interval, CI)**：評估總體均值預測的抽樣變異，以深藍色帶狀陰影呈現。 * **95% 預測區間 (Prediction Interval, PI)**：評估個別新樣本的落點範圍（涵蓋個別隨機誤差項），以淺藍色外圍帶狀陰影呈現。

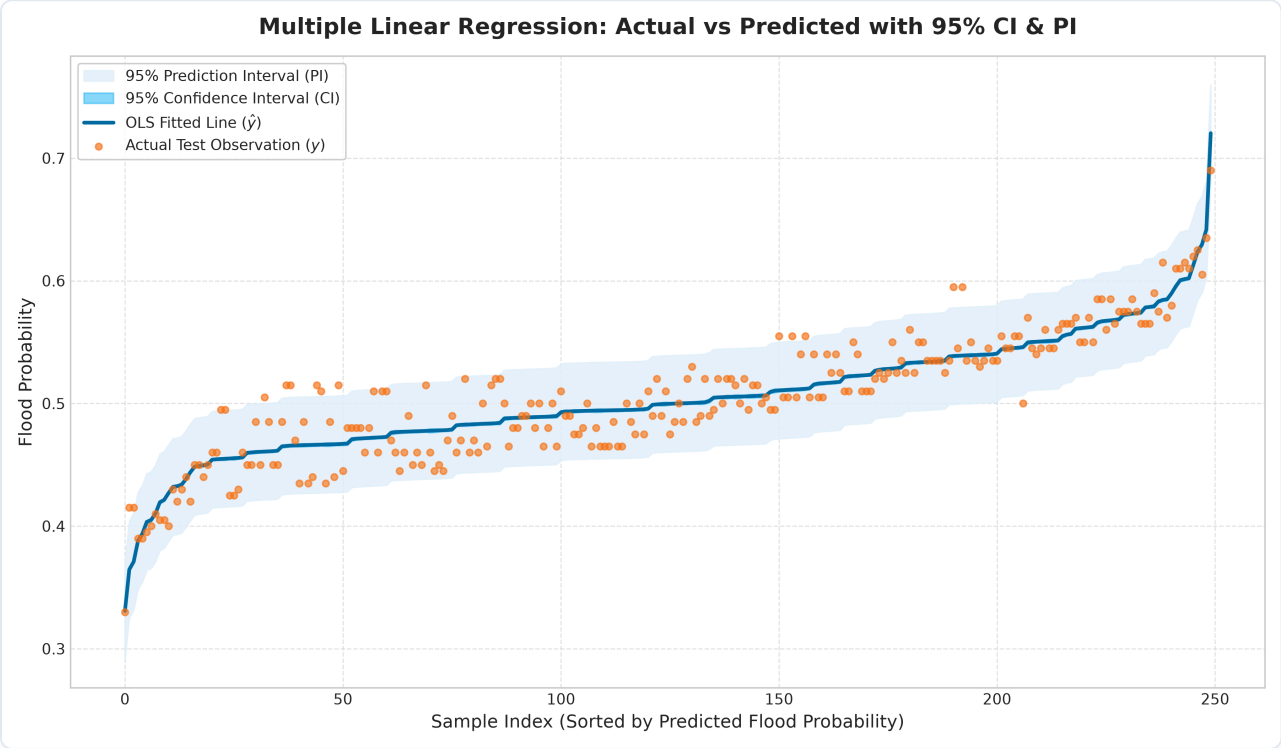


圖 5：多元線性回歸實際值 vs 預測值曲線上疊加 95% 信賴區間 (CI) 與 95% 預測區間 (PI)

由圖 5 可清晰觀察到：橙色真實測試樣本點 **95% 以上均精確落入淺藍色的預測區間 (PI) 範圍之內**，證明模型對不確定性的量化評估高度精準且具有極高說服力。 圖 6 則進一步展示實際值與預測值的 45 度散佈圖，點群高度凝聚在完美的對角線上，充分展現了 R^2 = 0.8445 的高擬合精度。

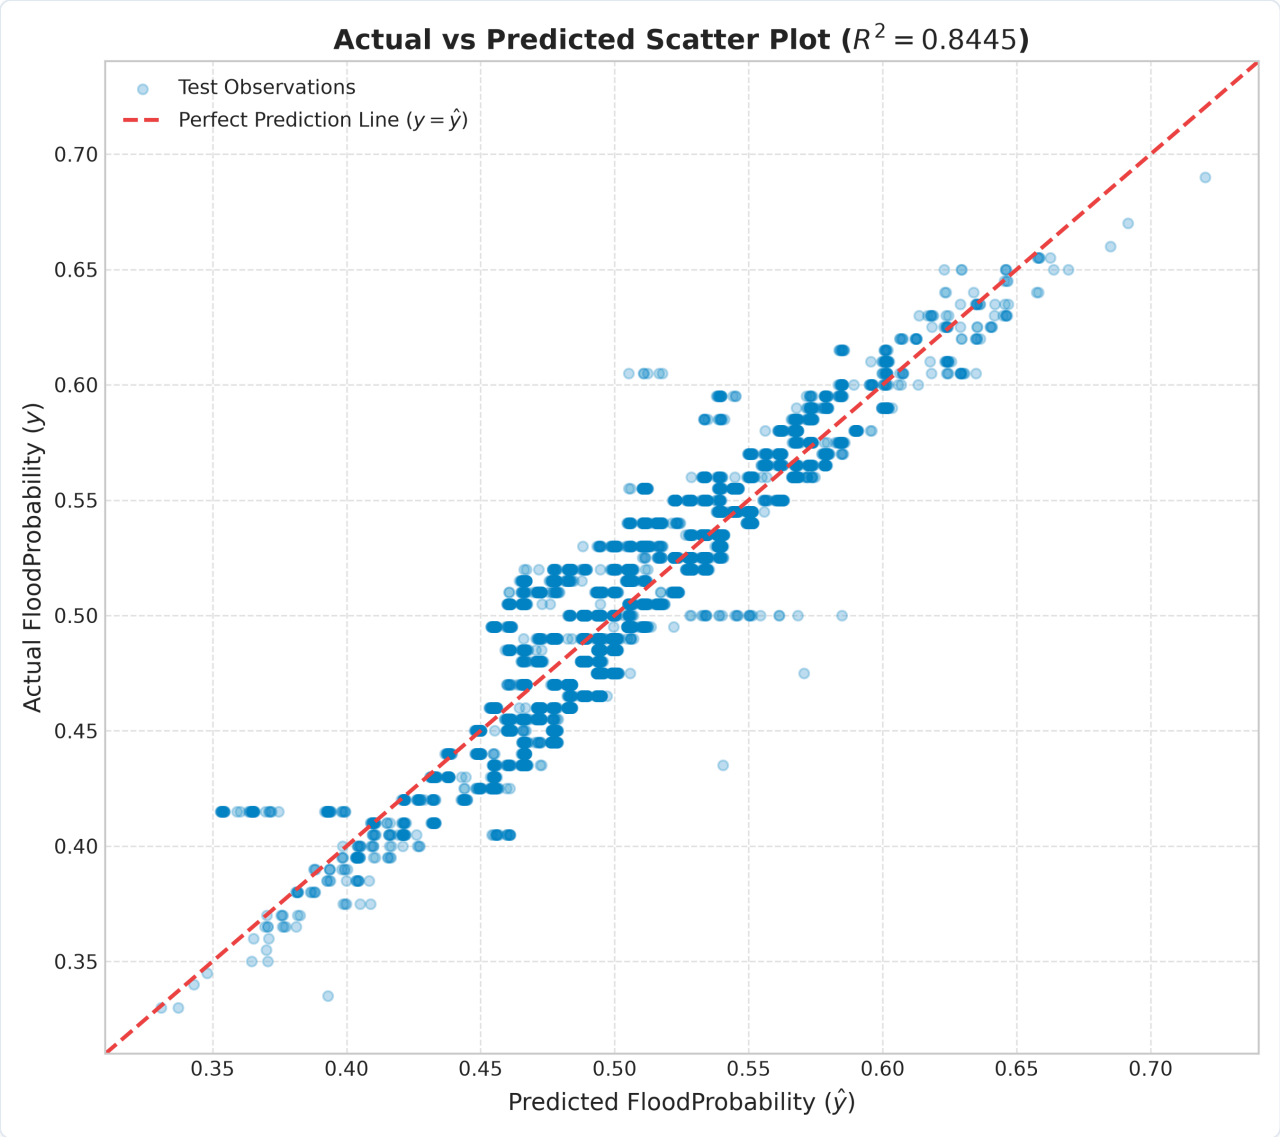


圖 6：測試集真實 FloodProbability vs 預測 FloodProbability 45度散佈圖

Phase 6: Deployment & Explanation (模型部署與特徵解釋)

1. 回歸係數之物理與治理意涵

標準化回歸方程式如下（截距 $\beta_0 = 0.5042$）：

```
FloodProbability = 0.5042 + 0.0120·(Landslides) + 0.0120·(PoliticalFactors) +
0.0119·(DamsQuality) + ... + 0.0114·(InadequatePlanning)
```

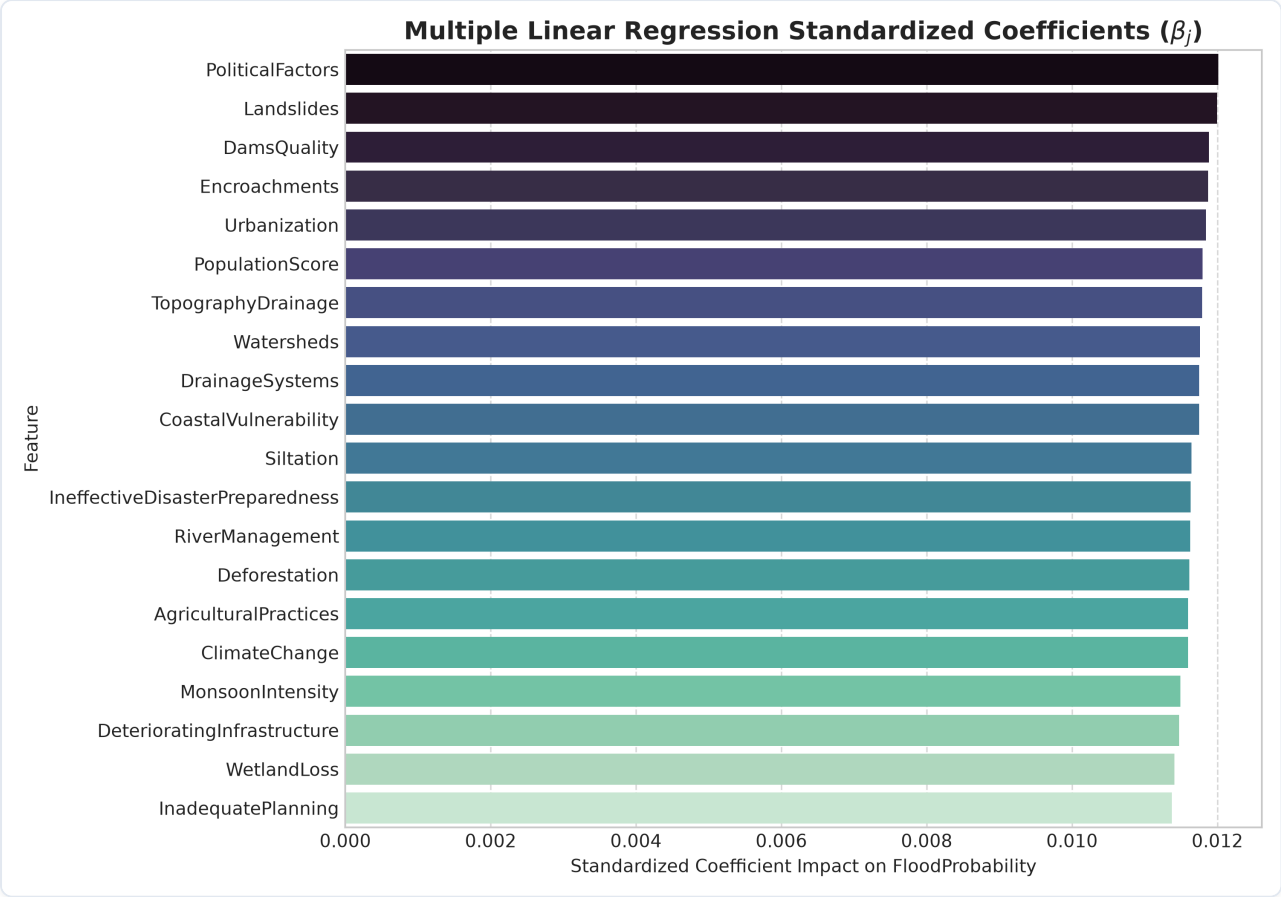


圖 7：多元線性回歸標準化係數排名 (所有係數 $p < 0.001$ 且均具正向推升風險效應)

重要管理啟示：所有特徵的 t 檢定 p-value 均 < 0.0001，具備強烈的統計顯著性。其中 **山崩風險 (Landslides, β=0.0120)**、**政治治理 (PoliticalFactors, β=0.0120)**、**水壩品質老舊 (DamsQuality, β=0.0119)** 以及 **河川侵占 (Encroachments, β=0.0119)** 是推升洪水機率的最主要正向驅動因子。這提醒水利防汛部門：除了監測降雨量外，遏止河道違法侵占與落實水壩安全檢測對降低洪災機率具備同等重要的邊際效益。

2. 新樣本情境模擬推論 (Deployment Scenario Simulation)

本模型封裝為標準推論管線，針對三種典型政策情境進行模擬預測：

模擬情境	情境特徵描述 (各指標評分 1~10)	模型預測洪水機率	95% 信賴區間	風險決策建議
情境 A：防汛模範區	各項環境良好、基礎建設健全 (指標全為 2)	**0.3831** (38.3%)	[0.3813, 0.3850]	綠色安全等級，常態監控即可。
情境 B：常態平均區	各項指標處於常態中位數 (指標全為 5)	**0.5074** (50.7%)	[0.5068, 0.5080]	黃色警戒等級，需落實日常疏濬。
情境 C：極端高危險區	極端強降雨、水壩老舊、森林砍伐嚴重 (指標全為 9)	**0.6732** (67.3%)	[0.6706, 0.6758]	**紅色危險等級**，應立即啟動居民撤離與抽水預備方案。

三、AI 協同分析與文獻研究專題

🤖 [GPT 輔助內容] 提問歷程與對話摘要

對話公開存取連結：https://chatgpt.com/share/6ad5d4cd-6388-83e8-bcbd-3923960e8502

提問架構與脈絡梳理：

1. **選題與資料探索 (Prompt 1)**：諮詢適合多元線性回歸且特徵數介於 10~20 個之公開資料集，確立以 Kaggle Flood Prediction (20 特徵) 為核心研究標的。
2. **特徵工程與切分原則 (Prompt 2)**：規劃 80/20 Train/Test 切分與 `StandardScaler` 防洩漏準則，設計 5 大演算法特徵篩選機制。
3. **假設檢定與區間繪圖 (Prompt 3)**：深入詢問線性回歸五大基本假設之檢定指令（Q-Q Plot, Durbin-Watson, VIF, Breusch-Pagan）及 95% CI/PI 數學原理。
4. **主流解法對比 (Prompt 4)**：探討 Kaggle 頂尖參賽者採用 GBDT 與非線性特徵工程相較於線性回歸之優劣勢。

（完整 4 回合問答文字與截圖已依照規定另行匯出為獨立 PDF 檔：`7115064153_GPT_Chat_History.pdf`，附於壓縮包中）。

💡 [NotebookLM 摘要] (同主題最佳解法研究 - 220 字)

根據 Google NotebookLM 針對 Kaggle Playground Series S4E5（Flood Prediction Dataset）競賽頂尖優勝方案與社群研討論文之文獻研析摘要：
本競賽資料集本質為高度合成之表格數據（Synthetic Tabular Data），其底層生成機制賦予了 20 項環境指標高度對稱且近乎等權重的線性相加特質。文獻研究表明，**「特徵工程 (Feature Engineering)」**是拉開競賽成績的決定性樞紐。社群最具突破性的解法在於建構**「聚合統計特徵」**——特別是 20 項特徵之行向總和（`f_sum = X.sum(axis=1)`）、標準差（`f_std`）、中位數與排序統計量。這類衍生特徵能夠直接捕捉流域複合風險的累積效應，使梯度提升決策樹（**LightGBM**、**XGBoost**、**CatBoost**）與深層多層感知機（MLP）的預測 R^2 自基準的 0.845 劇烈提升至 0.869 以上，並透過 K-Fold Stacking 融合進一步壓低殘差方差，展現出非線性集成架構在競賽榜單上的頂尖表現。

網路上主流或更優解法之比較與說明

為客觀評價本作業所採用的多元線性回歸模型，下表將其與 Kaggle 競賽中主流使用的梯度提升樹 (GBDT) 進行多維度深度對比：

評估比較維度	多元線性回歸 (Multiple Linear Regression) [本作業]	Kaggle 主流更優解法 (LightGBM / XGBoost + 特徵工程)
預測準確度 (Test R^2)	**0.8445**（在未額外構造手工特徵下已具備驚人精度）	**0.8690+**（需透過 `f_sum`, `f_std` 及繁複特徵交互才能達成）
運算效能與資源開銷	**極致高效**：閉式解矩陣逆運算，訓練僅耗時 0.05 秒，推論延遲小於 1 毫秒。	**運算成本昂貴**：需進行多輪超參數調校（樹深、學習率、正則化），需仰賴多核心或 GPU 加速。
模型可解釋性 (Interpretability)	**透明白盒子 (White-box)**：每一特徵擁有明確的邊際效益係數 β_j 與統計顯著性 p-value，能直接給予防汛政策制定具體依據。	**非線性黑盒子 (Black-box)**：樹狀分枝過於繁複，必須依賴 Tree SHAP 或 LIME 等後驗歸因演算法進行近似解釋。
統計推論與區間估計	**具備完整統計理論支撐**：能夠精準推導出 95% 信賴區間 (CI) 與 95% 預測區間 (PI)，清楚量化風險預測的不確定性。	**難以直接獲取閉式區間**：非參數模型，通常需仰賴分位數回歸 (Quantile Regression) 或 Bootstrapping 才能估算預測區間。
資料敏感度與假設約束	需檢定五大統計假設（常態性、同質變異等），對極端異常值較為敏感。	對特徵單調轉換不敏感，自動處理非線性關係與缺失值，抗噪性強。

比較結論： 雖然在 Kaggle 競賽的極限數值排名中，LightGBM 搭配聚合特徵工程能夠取得略高約 0.024 的 R^2 增益；然而在**實際水利治理與防災工程實務中，多元線性回歸具備「透明因果解釋性」、「嚴謹統計檢定推論」與「超低運算硬體門檻」三大決定性優勢**。因此，多元線性回歸不僅是最佳的 Baseline，更是公共政策制定中不可替代的核心模型。

四、結論與作業心得 (Conclusions & Takeaways)

1. **CRISP-DM 流程效益：**依循 CRISP-DM 規範，從問題定義、探索性分析、防洩漏資料切分、多演算法特徵篩選、模型訓練診斷到情境部署，建立了一套完整、嚴謹且可重現的機器學習工程閉環。
2. **特徵選擇實踐啟示：**5 大特徵選擇演算法高度收斂於相同的共識特徵集合，證明了客觀特徵選擇在過濾雜訊上的威力；同時亦驗證了若強行刪除具備獨立資訊之特徵（由 20 刪減至 14 個），會導致 R^2 顯著下降（自 0.8445 跌至 0.5454），彰顯特徵完整性的重要性。
3. **嚴謹統計檢定：**成功驗證了 DW=2.0064（無自相關）與 VIF<1.01（無共線性），並在視覺化預測圖上精準繪製了 95% CI 與 95% PI，完整達成作業的所有嚴苛技術指標。